Уральский федеральный университет имени первого Президента России Б.Н.Ельцина

Курс «Сбор и верификация данных»

Стратегия источников и ручной сбор

Тема 1.2. Источники, стратегия и краудсорсинг.

Уральский федеральный университет
имени первого Президента России Б.Н.Ельцина

Лекцию читает

Станислав Поляков

Старший преподаватель
Учебно-научный центр «Искусственный интеллект»
Институт радиоэлектроники и информационных технологий-РТФ
Уральский федеральный университет имени первого Президента России Б.Н. Ельцина

Сбор и верификация данных

Матрица Источников

- Классификация и архитектура источников данных: где лежат нужные нам датасеты?
- Стратегия сбора: приоритизация задач и аудит покупаемых данных.
- Когда автоматика бессильна: введение в ручную разметку и краудсорсинг.

Сбор и верификация данных

Глобальная классификация источников

Все источники данных можно разделить по двум основным осям, которые определяют сложность, легальность и стоимость сбора:

- **Ось X (Доступность):** Открытые (публичный доступ) vs Закрытые (требуют авторизации, покупки или NDA).
- **Ось Y (Происхождение):** Внутренние (генерируются самой компанией) vs Внешние (собираются из окружающего мира).

Внутренние + Открытые (Сайт компании)	Внутренние + Закрытые (Логи ERP)
Внешние + Открытые (Гос. реестры, Wikipedia)	Внешние + Закрытые (Купленные базы партнеров).

Сбор и верификация данных

Нужные определения

CRM (Customer Relationship Management) — это система управления взаимоотношениями с клиентами, программное обеспечение для автоматизации бизнес-процессов, хранения базы клиентов, учета сделок, звонков и писем.

ERP (Enterprise Resource Planning — планирование ресурсов предприятия) — это комплексная программная система, объединяющая все бизнес-процессы компании (финансы, производство, кадры, логистику, продажи) в единую базу данных. Она автоматизирует ручные операции, обеспечивает аналитику в реальном времени и помогает управлять ресурсами для повышения эффективности.

Сбор и верификация данных

Внутренние данные: CRM, ERP, Логи

Преимущества: Полный контроль над форматом и качеством (Data Governance). Данные бесплатны для компании, сбор полностью легален, отсутствует риск нарушения коммерческой тайны.

Недостатки: Ограниченный объем и узкий контекст. Вы знаете всё о своих клиентах, но абсолютно слепы в отношении тех, кто ушел к конкурентам или еще не совершил покупку.

Сбор и верификация данных

Внешние данные: Kaggle, Парсинг, API

Преимущества: Колоссальный масштаб. Позволяют обогащать внутренние профили пользователей, анализировать тренды рынка, следить за ценами конкурентов и обучать глобальные ML-модели.

Недостатки: Непредсказуемость. Форматы могут измениться без предупреждения. Высокий уровень «шума», необходимость сложной очистки и постоянные юридические риски (парсинг чужого контента).

Сбор и верификация данных

Классифицируем источники

1. Твиты с упоминанием вашего бренда. *(Внешние, Открытые — доступны всем, генерируются вне компании).*

2. Купленная выгрузка транзакций от банка-партнера. *(Внешние, Закрытые — требуют договора и денег).*

3. Метрики нагрузки на ваш корпоративный сервер. *(Внутренние, Закрытые — строгая коммерческая тайна).*

Сбор и верификация данных

Характеристики потока данных

Концепция 3-х «V» (Big Data)

Прежде чем писать код для парсера или подключать API, инженер должен оценить физику потока. Данные характеризуются тремя ключевыми параметрами:

- **Volume (Объем):** Сколько терабайт мы скачаем?
- **Variety (Разнообразие):** Сколько разных форматов придется склеивать?
- **Velocity (Скорость):** Как быстро данные устаревают и требуют обновления?

Сбор и верификация данных

Volume: Иллюзия дешевого Data Lake

Проблема: Цена хранения 1 Гб падает, но количество источников растет экспоненциально. Финансовая нагрузка на серверы может стать нерациональной.

Следствие: Озеро данных (Data Lake) без строгого контроля быстро превращается в «Болото данных» (Data Swamp), где невозможно найти полезную информацию, но за хранение которого бизнес платит огромные деньги.

Сбор и верификация данных

Variety: Притча про слона и мудрецов

Разнообразие источников дает полную картину.

Обратная сторона: Интеграция разных форматов (текст, логи, видео) требует колоссальных расходов на нормализацию. Правило: Не всегда возможно собрать всё воедино, а если и возможно — не всегда это экономически оправдано.

Сбор и верификация данных

Velocity: Срок годности данных

Какой объем требуется обрабатывать в единицу времени? Данные делятся на пакетные (исторические) и потоковые (Real-time).

Пример: Выборы президента США. Благодаря мгновенной обработке потока сообщений в Twitter (анализ тональности), штабы кандидатов понимали настроение избирателей прямо в ходе дебатов и на лету корректировали свою риторику. Вчерашние твиты там уже не имели ценности.

Сбор и верификация данных

Что делать, если мощностей не хватает?

Если поток данных превышает ваши возможности обработки, применяются четыре архитектурных паттерна:

- **Фильтрация:** Отбрасываем лишний шум еще до записи на жесткий диск.
- **Агрегация:** Сохраняем не каждую микро-транзакцию, а итоговые суммы за час/день.
- **Архивация:** Перенос «холодных» (старых) данных на дешевые ленточные накопители.
- **Обогащение:** Добавление ценного контекста на лету, чтобы не хранить исходный сырой лог.

Сбор и верификация данных

Почему мы не собираем всё подряд?

Время инженера, вычислительные мощности и бюджет на API жестко ограничены.

Любая задача по сбору данных должна проходить оценку ROI (Return on Investment — окупаемость инвестиций).

Мы делим запросы бизнеса на данные по трем уровням приоритета: **Высокий, Средний и Низкий.**

Сбор и верификация данных

Высокий приоритет (Делаем немедленно)

Эти задачи берутся в спринт первыми:

- **Критичность сроков:** У бизнеса острая потребность с жестким дедлайном (например, отчет для налоговой).
- **Высокий ROI:** Данные напрямую повышают прибыль или резко сокращают издержки.
- **Массовый спрос:** Одни и те же данные нужны сразу нескольким командам (маркетингу, продажам и ML-инженерам).
- **Ускользающий поток:** Ограниченное по времени «окно» сбора. Если не собрать эти потоковые данные сейчас, они исчезнут навсегда.

Сбор и верификация данных

Средний приоритет (Делаем в плановом режиме)

Хорошие, полезные задачи, которые могут немного подождать:

- **Обогащение базы:** Новые данные дополняют имеющиеся и улучшают качество ML-модели, но система работает и без них.
- **Переиспользование кода:** Если у нас уже написан парсер для похожего сайта, собрать еще один будет быстро и дешево.
- **Доступность историчности:** У источника есть удобный API с архивом за 5 лет. Данные не сгорят, мы всегда сможем забрать их позже.

Сбор и верификация данных

Низкий приоритет (Откладываем в бэклог)

Задачи, от которых дата-инженер должен уметь отказываться:

- **Низкое качество:** Источник нестабилен, данные мусорные. Использование таких данных принесет больше вреда (багов), чем пользы.
- **Чрезмерные усилия:** Сложный Web Scraping сайтов с жесткой защитой от ботов ради крошечной выгоды.
- **Синдром «А вдруг пригодится»:** Вероятность использования данных стремится к нулю. Мотивация «зато с этими данными мы сможем грабить корованы!» — не повод тратить ресурсы сервера.

Сбор и верификация данных

Сбор и покупка данных (Чек-лист)

Когда пора покупать данные?

- Все любят бесплатные датасеты — и руководство, и аналитики.
- Но на практике бесплатный парсинг часто обходится дороже (постоянные поломки кода, блокировки серверов, чистка мусора), чем покупка официального корпоративного API.
- Перед тем как подписать договор с поставщиком (Data Provider), необходимо провести строгий аудит источника по чек-листу.

Сбор и верификация данных

Бизнес-критерии покупки

- **Цена vs Ценность:** Окупает ли датасет затраты на свое приобретение?
- **Эксклюзивность**: Подготовлены ли данные индивидуально для вас, или конкуренты могут купить то же самое за углом? (Наличие преимущества).
- **Условия использования (Лицензии):** Можно ли использовать эти данные в коммерческих ML-моделях? Есть ли ограничения на перепродажу третьим лицам?

Сбор и верификация данных

Технические критерии интеграции

- **Формат и Документация:** Насколько легко интегрировать эти данные в нашу архитектуру? Есть ли Swagger/документация API для разработчиков?
- **Обновления (TTL):** Как быстро эти данные устаревают? Гарантирует ли провайдер частоту обновлений (раз в час, раз в сутки)?
- **Степень детализации:** Что мы покупаем? Сырые логи (максимум гибкости, но тяжело хранить) или агрегированную статистику (легко работать, но нельзя посмотреть вглубь)?

Сбор и верификация данных

Качество и Безопасность

- **Пробная выборка (Sampling):** Предоставляет ли продавец тестовый кусок данных до оплаты, чтобы мы могли оценить количество пропусков и ошибок?
- **Надежность инфраструктуры:** Какие у провайдера лимиты (Rate limits) на скачивание? Не упадет ли их сервер в черную пятницу?
- **Безопасность и PII:** Содержат ли данные персональную информацию пользователей? Как они зашифрованы при передаче (HTTPS/TLS)?

Сбор и верификация данных

Пределы возможностей парсеров и API

Почему скриптов недостаточно?

- Парсеры (BeautifulSoup) и API отлично справляются с добычей сырых структурированных фактов: цен, дат, координат, имен.
- **Проблема:** Алгоритмы слепы к контексту. Парсер скачает текст отзыва, но не скажет, скрыт ли в нем сарказм. Скрипт скачает 1000 фотографий улиц, но не сможет выделить на них светофоры.
- Для обучения моделей машинного обучения (Supervised ML) нам нужна не просто сырая информация, а «Истина в последней инстанции» (Ground Truth).

Сбор и верификация данных

Человеческий интеллект как источник данных

Там, где заканчивается структурированная логика и начинается интерпретация, в процесс сбора данных вступает человек.

Что собирают вручную:

- **Компьютерное зрение (CV):** Выделение объектов (Bounding boxes), сегментация пикселей.
- **Обработка естественного языка (NLP):** Определение тональности текста, поиск спама, извлечение именованных сущностей (NER).
- **Аудио:** Транскрибация речи (Speech-to-text) с учетом акцентов и шума.

Сбор и верификация данных

Внутренняя экспертиза (In-house Labeling)

Разметка экспертами: Дорого, но точно

Первый способ ручного сбора — нанять штатных экспертов (In-house асессоров).

- **Пример:** Разметка рентгеновских снимков для поиска опухолей. Эту задачу нельзя доверить случайному человеку из интернета, нужен врач-онколог.
- **Плюсы:** Максимальная точность, защита коммерческой/медицинской тайны, глубокое погружение в контекст задачи.
- **Минусы:** Огромная стоимость, невозможность быстрого масштабирования (нельзя нанять 1000 врачей за один день).

Сбор и верификация данных

Как масштабировать человека?

Если задача не требует докторской степени (например, отличить кошку от собаки или позитивный отзыв от негативного), нанимать экспертов — это сжигание бюджета.

Решение — Краудсорсинг (Crowdsourcing): Передача микро-задач огромной распределенной толпе неквалифицированных исполнителей через интернет.

Сотня обычных людей за 1 час сделает тот же объем работы, который один штатный сотрудник делал бы месяц.

Сбор и верификация данных

Краудсорсинг и Разметка (Платформы)

Как устроены биржи микрозадач?

Краудсорсинг — это Uber для данных. Платформа сводит Заказчика и Исполнителей.

Заказчик (Реквестер): Загружает сырой датасет (например, 100 000 фото), пишет инструкцию, устанавливает цену за 1 микро-задачу (например, $0.01) и пополняет баланс.

Исполнитель (Воркер): Берет задачи в работу в свободное время, выполняет их через веб-интерфейс и мгновенно получает центы на свой счет.

Платформа: Предоставляет интерфейс и берет комиссию (около 20-30%).

Сбор и верификация данных

Где искать исполнителей?

- **Яндекс.Задания (Tasks):** Де-факто стандарт в РФ и СНГ. Огромная база русскоязычных исполнителей, идеальна для NLP и модерации контента.
- **Amazon Mechanical Turk (MTurk):** Пионер рынка. Глобальная аудитория, отлично подходит для задач на английском языке и сложных исследований.
- **Scale AI / Snorkel:** Платформы нового поколения. Сами управляют качеством, предоставляют готовые API (дорого, но под ключ).
- **Проектный практикум в УРФУ:** Самый актуальный рынок исполнителей в нашем случае.

Сбор и верификация данных

Инструменты для In-house разметки

Что делать, если данные нельзя отдавать во внешний интернет (NDA, персональные данные, банковская тайна)?

В этом случае мы разворачиваем **LabelStudio** (или аналоги, например, **CVAT**) на собственных серверах компании.

Это Open-Source интерфейс, в котором работает только ваша внутренняя команда асессоров. Вы не платите за каждую задачу, а платите зарплату сотрудникам.

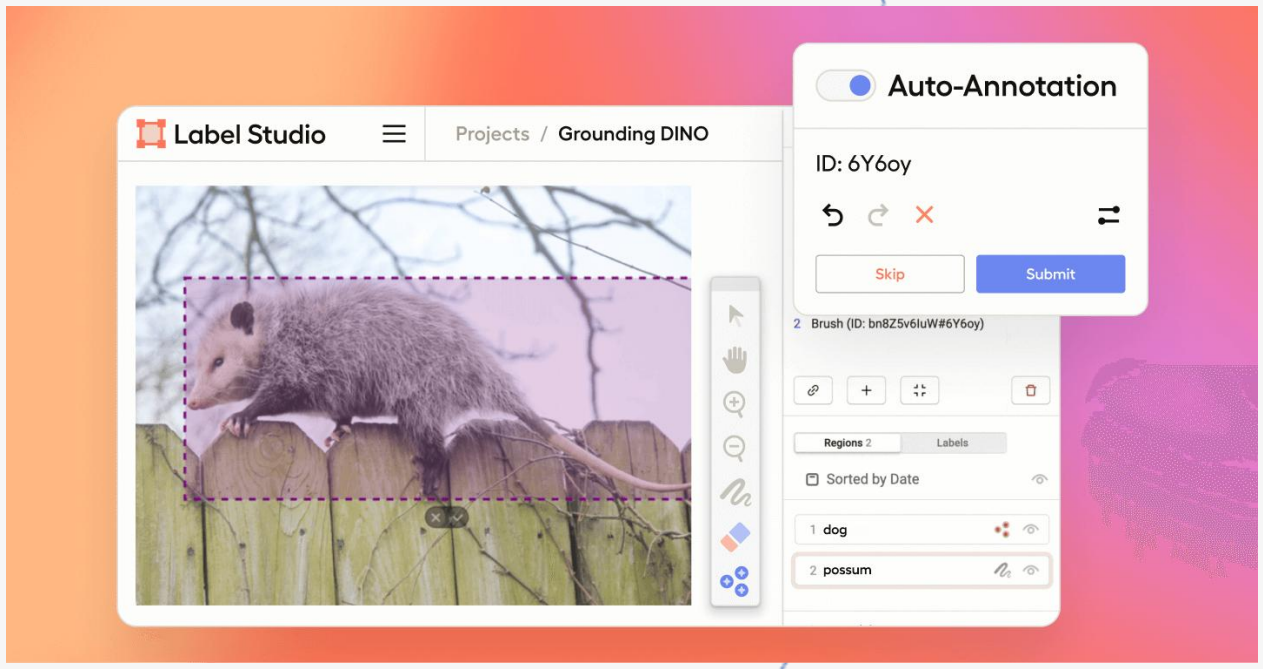

Сбор и верификация данных

Подводные камни краудсорсинга

- Толпа быстрая и дешевая, но непредсказуемая.
- **Боты и кликеры:** Люди пишут скрипты, чтобы автоматически «прокликивать» ваши задачи наугад и забирать деньги.
- **Спешка:** Исполнитель хочет заработать больше за час, поэтому читает тексты по диагонали и часто ошибается.
- **Вывод:** В краудсорсинге мы платим не столько за саму работу, сколько за выстраивание жесткой системы контроля качества.

Сбор и верификация данных

Анатомия идеального технического задания

- Если инструкцию можно понять двояко — исполнители обязательно поймут ее неправильно.
- Заказчик просит: «Выделите машины на фото». Один обводит легковушки. Второй обводит игрушечные машинки. Третий обводит грузовики. Четвертый обводит отражение машины в витрине.
- Итог: Датасет полностью испорчен, деньги потрачены зря. Модель машинного зрения сойдет с ума.

Сбор и верификация данных

Как писать инструкции?

Хорошая инструкция для краудсорсинга должна содержать:

1. **Четкую цель:** Однозначное описание того, что требуется сделать (1-2 предложения).
2. **Edge cases (Пограничные случаи):** Подробный разбор неочевидных ситуаций (Что делать, если картинка размыта? Что делать, если текст на иностранном языке?).
3. **Примеры с пояснениями:** Обязательно таблица: «Вот так — правильно, вот так — ошибка, и вот почему».
4. **Правило:** Если 12-летний подросток не понял инструкцию за 3 минуты — переписывайте.

Сбор и верификация данных

Эргономика интерфейса (UX)

Исполнитель делает 1000 задач в день. Каждое лишнее движение мышкой повышает его усталость и снижает качество ваших данных.

Золотые правила интерфейса разметки:

- Минимум скроллинга (все на одном экране).
- Использование горячих клавиш (Hotkeys). Например: Цифра 1 — Позитив, Цифра 2 — Негатив, Цифра 3 — Нейтрально.
- Крупные и контрастные шрифты.

Сбор и верификация данных

Медовые ловушки (Golden Tasks)

Как отловить ботов и халтурщиков?

Для контроля качества мы используем Golden Tasks (Контрольные задания).

- До загрузки данных на биржу аналитик сам идеально размечает 5% датасета (создает эталоны).
- Эти эталоны скрыто подмешиваются в общий пул задач. Исполнитель не знает, где реальная задача, а где проверка.
- Если исполнитель ошибается в 3-х контрольных заданиях подряд — система автоматически банит его и аннулирует все его ответы.

Сбор и верификация данных

Метод простого большинства (Majority Vote)

Голосование большинства: Плюсы и минусы

Самый простой способ агрегации: если 3 из 5 человек сказали, что отзыв позитивный — принимаем ответ «Позитивный».

Преимущества: Легко запрограммировать (в Pandas это функция .mode()).

Фатальный недостаток: Метод не учитывает вероятность случайного угадывания. В бинарной задаче (Да/Нет) шанс совпадения мнений у двух слепых кликеров составляет целых 50%! Нам нужна более строгая метрика.

Сбор и верификация данных

Математика доверия (Cohen's Kappa)

Каппа Коэна – это статистический показатель, измеряющий степень согласованности между двумя оценщиками (экспертами, моделями классификации), классифицирующими объекты по номинальным категориям. В отличие от простой точности, он учитывает вероятность случайного совпадения оценок, что делает его надежным для несбалансированных данных.

Сбор и верификация данных

Математика доверия (Cohen's Kappa)

Как проверить задачу, если для нее нет "Золотого стандарта"? Например, оценка: «Насколько смешной этот мем по 5-балльной шкале?».

Люди субъективны. Чтобы найти «истину», мы используем перекрытие (Overlap).

Мы отдаем одну и ту же задачу 3 или 5 независимым исполнителям.

Ожидание: они должны прийти к одному выводу. Если мнения разделились поровну, значит, задача поставлена некорректно.

Сбор и верификация данных

Каппа Коэна (к): Убираем фактор случайности

Каппа Коэна — это статистическая метрика, которая измеряет надежность согласованности оценок между двумя независимыми асессорами.

В отличие от простого процента совпадений, формула Каппы математически вычитает вероятность того, что исполнители дали одинаковые ответы чисто случайно.

Это золотой стандарт в научных статьях (МФТИ/ВШЭ) и серьезных ML-проектах для доказательства чистоты данных.

$$\frac{(\text{Реальное совпадение мнений - Случайное совпадение})}{(1 - \text{Случайное совпадение})}.$$

Сбор и верификация данных

Интерпретация значений Каппы

Диапазон метрики: от ≤0 до 1

- **к<0:** Мнения расходятся хуже, чем если бы они просто подкидывали монетку (асессоры делают назло).
- **0.01–0.20:** Незначительное согласие (Данные мусор).
- **0.41–0.60:** Умеренное согласие.
- **0.61–0.80:** Существенное согласие (Можно отдавать в ML).
- **0.81–1.00:** Почти идеальное согласие (Встречается крайне редко).

Важно: Если Каппа низкая — в 90% случаев виноваты не люди, а ваша запутанная инструкция!

Сбор и верификация данных

Почему люди систематически ошибаются?

Машины ошибаются случайно (из-за багов), а люди ошибаются систематически из-за особенностей психики.

Даже самый честный и мотивированный асессор подвержен когнитивным искажениям (Cognitive Biases).

Если не учитывать эти искажения на этапе проектирования интерфейса разметки, ваш итоговый DataFrame будет отравлен субъективностью, **которую не выявит ни одна математическая проверка**.

Сбор и верификация данных

Ловушки мышления в разметке

Предвзятость подтверждения (Confirmation Bias): Асессор неосознанно ищет в тексте то, что подтверждает его личные убеждения. Пример: Фанаты Apple будут чаще размечать отзывы о Samsung как «негативные», даже если текст нейтрален.

Эффект ореола (Halo Effect): Если первые 10 задач были про спам, на 11-й задаче человек по инерции нажмет кнопку «Спам», даже не вчитываясь в нормальный текст.

Культурный контекст: Шутка, понятная студенту из Москвы, может быть размечена как "Токсичность" асессором из другого региона.

Сбор и верификация данных

Деградация качества во времени

Внимание человека — это исчерпаемый ресурс. Исследования показывают, что после 40 минут монотонной разметки (например, выделения лиц на фото) качество ответов падает на 30-50%.

Асессоры начинают использовать эвристики (упрощения): выбирают самый короткий вариант ответа, перестают читать длинные тексты, жмут кнопки наугад.

Сбор и верификация данных

Как лечить человеческий фактор?

Инженер данных должен выстроить защиту на уровне платформы:

- **Динамическое ценообразование:** Платить больше за сложные задачи, чтобы компенсировать когнитивную нагрузку.
- **Принудительные паузы:** Искусственно блокировать выдачу заданий одному исполнителю после часа работы (защита от выгорания).
- **Рандомизация:** Перемешивать классы задач, чтобы не создавать у асессора эффект «замыленного глаза» от однотипных картинок.

Сбор и верификация данных

Смена парадигмы: Batch vs Stream

Batch (Пакетная): Данные собираются в кучу, лежат на диске, и раз в сутки (неделю, месяц, год) скрипт их обрабатывает. Это как набрать ведро воды из колодца. (CSV, JSON-дампы).

Stream (Потоковая): Данные генерируются непрерывно и требуют мгновенной реакции (миллисекунды). Это как пить из пожарного гидранта.

Биржевые котировки, антифрод в банках, телеметрия беспилотников — здесь ручной сбор и обычные парсеры абсолютно бесполезны.

Сбор и верификация данных

Анатомия потока (Event-Driven)

В потоковой архитектуре мы собираем не "состояния", а "события".

Событие (Event): Это факт того, что что-то произошло. У него есть метка времени (Timestamp), идентификатор (ID) и полезная нагрузка (Payload).

Пример: Не «У Ивана на счету 100 рублей», а «В 12:00:01 Иван перевел 50 рублей Петру». Из потока таких событий мы можем в любой момент восстановить текущий баланс.

Сбор и верификация данных

Брокеры сообщений (Apache Kafka)

Инструменты data-инженера: **Kafka**

- Нельзя напрямую отправлять миллионы событий в базу данных — она упадет от нагрузки.
- Для сбора потоковых данных используют брокеры сообщений (стандарт индустрии — **Apache Kafka**).
- **Kafka** работает как гигантский амортизатор: она мгновенно принимает сырые данные в оперативную память, выстраивает их в очередь и отдает аналитическим скриптам с той скоростью, с которой они способны их переварить.

Сбор и верификация данных

Проблемы Real-time сбора

Потеря пакетов: Что делать, если датчик IoT отключился от Wi-Fi на 5 секунд? У нас дыра в данных.

Out-of-order events (Нарушение порядка): Из-за задержек сети событие, произошедшее в 12:05, может прийти на сервер раньше, чем событие из 12:04.

Сбор потоковых данных требует сложнейшей логики "окон" (Windowing) для сортировки хаоса в реальном времени.

Сбор и верификация данных

Персональные данные (PII)

PII (Personally Identifiable Information) — это любая информация, позволяющая однозначно идентифицировать конкретного человека.

Часто содержит имена, номера телефонов, геолокация, IP-адреса, история болезней и т.д.

Для дата-инженера такие данные — это токсичный материал. Их сбор и хранение строго регламентированы, а утечка грозит уничтожением бизнеса и уголовными делами.

Сбор и верификация данных

Правовое поле сбора данных (GDPR и 152-ФЗ)

GDPR (Европа): Самый жесткий закон в мире. Огромные штрафы (до 4% от мирового оборота компании) за сбор данных без явного согласия пользователя. Ввел право "быть забытым".

152-ФЗ (Россия): Требует хранить данные россиян на серверах внутри РФ и обязывает получать согласие на обработку.

Вывод: Прежде чем писать парсер для социальной сети или покупать слитую базу, проконсультируйтесь с юристами.

Сбор и верификация данных

Анонимизация и Псевдонимизация

Чтобы легально передать данные аналитикам, мы обязаны скрыть личности.

Анонимизация: Необратимое удаление PII с сохранением статистически значимых деталей. (Было: Иван, 25 лет. Стало: Мужчина, 20-30 лет).

Псевдонимизация: Замена имен на хеш-коды (Было: Иван. Стало: User_7A8B9). Можно расшифровать обратно, если есть секретный ключ.

Сбор и верификация данных

Синтетические данные как выход

Что делать, если нам нужны медицинские данные для обучения нейросети, но из-за врачебной тайны мы не можем собрать настоящие карты пациентов?

Ответ: Генерация синтетических данных. Мы создаем математические модели (GANs), которые генерируют полностью выдуманных пациентов, сохраняя при этом общие статистические свойства реальных болезней.

Сбор и верификация данных

Выводы (Recap)

1. Источники бывают внутренние и внешние. Бесплатных данных не бывает.
2. Big Data оценивается по трем "V" (Volume, Variety, Velocity).
3. Перед парсингом или покупкой нужно оценить ROI и составить чек-лист качества.
4. Там, где скрипты слепы, в дело вступает краудсорсинг (таски от Яндекса).
5. Качество разметки измеряется Каппой Коэна, а сбор персональных данных карается законом.

Уральский федеральный университет
имени первого Президента России Б.Н.Ельцина

Спасибо за внимание!

Курс «Сбор и верификация данных»
Поляков Станислав Олегович